Flash Card #1

Reto III: NLP RAG & Embeddings

Gabriel Efrain Condes Luna

Descripción del reto

- Reto: Implementar una arquitectura RAG para construir un chatbot capaz de responder preguntas sobre la Ley Federal para la Prevención e Identificación de Operaciones con Recursos de Procedencia Ilícita.
- Datos: Los datos están representados por el texto completo de la ley, el cual fue procesado mediante limpieza, segmentación en chunks y recuperación de contexto usando distintos métodos como BM25 y embeddings.

Solución

Descripción del modelo: Se construyó una arquitectura RAG compuesta por una etapa de limpieza y preprocesamiento del texto, diferentes métodos de chunking, un componente de recuperación de información y un modelo generativo para responder preguntas usando únicamente el contexto recuperado. Se evaluaron distintas configuraciones combinando BM25, embeddings de OpenAI, tamaños de chunk, traslapes y métodos de segmentación.
ML packages: Se utilizaron principalmente OpenAI, rank_bm25, pandas y utilidades estándar de Python. Para la generación de respuestas y evaluación automática se usó gpt-4.1-mini; para embeddings se utilizó text-embedding-3-small.
Performance: Se definieron tres métricas de evaluación: Answer Relevancy, Faithfulness y Context Relevancy. Cada métrica se calificó como GOOD, REGULAR o BAD, asignando valores numéricos de 2, 1 y 0 respectivamente. La mejor configuración fue seleccionada con base en el mayor promedio global de estas métricas.

Preguntas a resolver

- ¿El chatbot pudo responder correctamente las preguntas sobre la ley?: Sí. El sistema RAG logró recuperar fragmentos relevantes del documento y generar respuestas basadas en el contexto recuperado.
- ¿Qué configuración del RAG tuvo mejor desempeño?: Bajo nuestro esquema de evaluación, varias configuraciones obtuvieron la mejor puntuación. Esto indica que la evaluación debería hacerse más robusta para que las diferencias de rendimiento entre configuraciones sean más distinguibles.

Desafíos

- Las técnicas de preprocesamiento y chunking deben ajustarse al dominio específico del texto legal, ya que la estructura por artículos, fracciones, incisos y reformas puede afectar la calidad de la recuperación.
- El formato del documento presentó retos, como encabezados, saltos de página, marcas del Diario Oficial y secciones transitorias que debían tratarse cuidadosamente.
- Algunas preguntas legales requieren distinguir entre conceptos similares, como umbrales de identificación y umbrales de Aviso, autoridades competentes, obligaciones y sanciones.
- Aunque no se implementó, sería conveniente adaptar más los prompts para considerar sutilezas del lenguaje jurídico y evitar respuestas ambiguas.
- La evaluación podría hacerse más robusta, ya que varias configuraciones obtuvieron la misma puntuación máxima bajo el esquema actual.

Conclusiones

- Se implementó una arquitectura RAG capaz de responder preguntas sobre un documento legal utilizando recuperación de contexto y generación de respuestas con un LLM. La solución permitió configurar distintos parámetros y componentes, como el tipo de preprocesamiento del texto, el método de chunking, el tamaño de los chunks, el traslape entre chunks, el tipo de retriever, el número de chunks recuperados (k) y el modelo usado para generar las respuestas. También se incorporaron métodos de recuperación basados en BM25 y embeddings de OpenAI.
- Bajo el esquema de evaluación utilizado, varias configuraciones obtuvieron la mejor puntuación, por lo que sería necesario diseñar una evaluación más robusta para distinguir mejor su rendimiento.
- En textos legales, es importante adaptar el preprocesamiento, la segmentación y los prompts al formato jurídico, ya que pequeños matices pueden cambiar la respuesta correcta.
- Como trabajo futuro, se podrían incorporar métricas más finas, más preguntas de evaluación y prompts especializados en razonamiento legal.

Public