Problemática

- **Contexto**: BBVA cuenta con un ecosistema tecnológico maduro y un sólido gobierno de datos (tablas masterizadas, diccionarios, esquemas, documentación de negocio y repositorios de código).
- **Problema**: A pesar del gobierno de datos, los formatos actuales (diccionarios y esquemas) no son amigables para aprender a utilizar las tablas en el día a día. Es difícil identificar rápidamente el nivel de agregación, los filtros clave o la tabla ideal para un nuevo desarrollo.
- **Impacto**: Curvas de aprendizaje prolongadas para el uso de tablas nuevas, lo que ralentiza el time to value de los proyectos de datos.
- **Solución (RAG)**: Un asistente para desarrolladores que permita consultas en lenguaje natural (ej. "Quiero resolver X problema, necesito datos de X naturaleza" o "Háblame más de la tabla Y"). El sistema sugerirá tablas, describirá campos clave y proporcionará snippets de código con casos de uso previos.

Naturaleza de los Datos con los que se trabajará

- **Tipo de Datos (Corpus del RAG)**: Se utilizará información puramente estructural y técnica, dividida en tres fuentes principales:
  - *Metadatos y Diccionarios*: Esquemas de tablas, descripciones de campos, tipos de datos y niveles de agregación.
  - *Documentación de Negocio*: Documentos de arquitectura y requerimientos funcionales de los proyectos que generan o consumen los datos.
  - *Repositorios de Código*: Scripts (SQL, Python/Spark) extraídos de repositorios internos que muestran cómo se filtran, cruzan y utilizan las tablas en la práctica.
- **Restricciones de Privacidad**: El sistema es completamente seguro, ya que solo se ingiere metadata, documentación y lógica de programación. No se indexará ni procesará ningún tipo de dato transaccional real, saldos, ni Información Personal Identificable (PII) de los clientes del banco.

Hipótesis y Modelos Matemáticos

- **Hipótesis Principal**: El uso de un sistema RAG para disminuir la brecha entre las necesidades del negocio y las capacidades técnicas de los datos aumentará significativamente la eficiencia en los equipos de desarrollo.
- **Diseño de Búsquedas Paralelas**: Para consolidar respuestas mucho más completas y precisas, se propone una arquitectura RAG que ejecute múltiples vías de búsqueda de forma simultánea:
    - 1. ***Búsqueda Jerárquica en Documentación***: Los documentos estarán organizados por proyecto.
        - *Fase A*: Usando modelos de incrustaciones (embeddings) y Similitud del Coseno, el sistema primero buscará qué proyecto histórico tiene un caso de uso semánticamente parecido al que se está solicitando.
        - *Fase B*: Posteriormente, el sistema acotará la búsqueda para extraer la información útil solo dentro de los documentos de ese proyecto específico.
    - 2. ***Búsqueda en Metadata*** (Paralela e Independiente): Al mismo tiempo, se realizará una búsqueda directa en los diccionarios y esquemas de datos. Aquí, se proponen modelos probabilísticos de recuperación exacta (como BM25 / TF-IDF) para asegurar coincidencias precisas con nombres técnicos de tablas o columnas.
    - 3. ***Búsqueda en Repositorios de Código***: Una tercera búsqueda paralela explorará los repositorios para recuperar snippets de código (SQL/Spark) relacionados con la consulta.
    - ***Consolidación***: El modelo generativo recibirá el contexto de estas tres fuentes (caso de uso del proyecto + metadata exacta + código fuente) para armar una respuesta unificada, sugiriendo al usuario exactamente qué tablas usar, sus campos y cómo programarlas.